

第8章 数据集工程

模型的质量取决于其训练数据的质量。即使是世界上最优秀的机器学习团队，拥有无限计算资源，如果没有数据，也无法帮助你微调出一个好模型。数据集工程的目标是创建一个能让你在理想情况下在预算范围内训练出最佳模型的数据集。

随着越来越少的公司能够负担从头开发模型的成本，更多的公司正转向通过数据来使其AI性能差异化。随着模型对数据需求的增加，数据处理变得更具挑战性，需要更多的人才和基础设施投资。

数据操作已经从人们在空闲时间处理的附带任务，演变为专门的角色。许多AI公司现在雇用数据标注员、数据集创建者和数据质量工程师，他们要么集成到核心工程团队中，要么与其一起工作。

如果模型领域因众多产品而令人困惑，那么数据领域则更加复杂，有不断增长的数据集和技术被引入。本章将概述数据领域和构建自己数据集时需要考虑的因素。

本章从数据策划开始，解答诸如：你需要什么数据？需要多少？什么样的数据被视为高质量？然后讨论数据合成和处理技术。数据策划、生成和处理并不遵循线性路径。你可能需要在不同步骤之间来回切换。

对于同一个模型，不同的训练阶段旨在教授模型不同的能力，因此需要具有不同属性的数据集。例如，预训练的数据量通常以token数量来衡量，而监督微调的数据量通常以样本数量来衡量。然而，在高层次上，它们的策划过程遵循相同的原则。本章重点关注后训练数据，因为这对应用开发者更相关。不过，当预训练数据的经验对后训练有启发时，我也会包括这些经验。

你可以遵循最佳实践并使用工具来自动化部分流程。然而，数据主要还是由辛勤、泪水和汗水组成的。

以数据为中心的AI视角

AI开发过程中对数据的日益关注催生了以数据为中心的AI，这与以模型为中心的AI相对：

- 以模型为中心的**AI**试图通过增强模型本身来提高AI性能。这包括设计新架构、增加模型规模或开发新的训练技术。
- 以数据为中心的**AI**试图通过增强数据来提高AI性能。这包括开发新的数据处理技术和创建高质量数据集，使更好的模型能够以更少的资源进行训练。

在深度学习早期，许多AI基准测试是以模型为中心的。给定一个像ImageNet这样的数据集，人们尝试使用相同的数据集训练最好的模型。近年来，更多的基准测试变得以数据为中心。给定相同的模型，人们尝试开发一个能让该模型表现最佳的数据集。

2021年，Andrew Ng发起了一个以数据为中心的AI竞赛，参与者需要通过应用技术如修复错误标签、添加边缘案例、增强数据等来改进同一基础数据集。

2023年，DataComp (Gadre等, 2023)举办了一个竞赛，其目标是创建用于训练CLIP模型(Radford等, 2021)的最佳数据集。一个标准化脚本在每个提交的数据集上训练CLIP模型。数据集的质量基于其所得模型在38个下游任务中的表现进行评估。2024年，他们举办了类似的竞赛，评估用于参数范围从412M到7B的语言模型的数据集(Li等, 2024)。其他类似的以数据为中心的基准包括DataPerf (MLCommons, 2023)和dcbench (Eyuboglu和Karlaš, 2022)。

以模型为中心和以数据为中心的划分有助于指导研究。然而，在现实中，有意义的技术进步通常需要同时投资于模型和数据的改进。

数据策划

虽然并非所有AI模型的问题都能通过数据解决，但数据通常是解决方案的关键部分。适当的数据可以使模型更有能力、更安全，并能处理更长的上下文。相反，糟糕的数据可能导致模型增加偏见和幻觉。数据中的错误可能损害模型并浪费资源。

数据策划是一门需要理解模型如何学习以及有哪些可用资源来帮助其学习的科学。数据集构建者应与应用和模型开发者密切合作。在小型团队中，他们可能是同一个人——负责训练模型的人也负责为其获取数据。然而，数据需求高的组织通常会雇用专门的角色。

你需要什么数据取决于你的任务和你想教授模型什么。对于自监督微调，你需要数据序列。对于指令微调，你需要(指令，回应)格式的数据。对于偏好微调，你需要(指令，优胜回应，落败回应)格式的数据。要训练奖励模型，你可以使用与偏好微调相同的数据格式，或使用((指令，回应)，分数)格式的带有注释分数的数据。

训练数据应展现你希望模型学习的行为。获取高质量的数据注释总是具有挑战性，但如果你想教导模型复杂行为，如思维链(CoT)推理和工具使用，则更具挑战性。让我们来看看这两个例子，了解为什么：

思维链

如第5章所讨论，CoT提示引导模型在给出最终答案前逐步解决问题。为了教导模型生成逐步回应，其训练数据应包括CoT回应。"扩展指令微调语言模型"(Chun等, 2024)显示，在微调数据中包含逐步回应大大增强了各种规模模型在CoT任务上的表现，对某些任务的准确率几乎翻倍。

生成多步骤回应可能繁琐且耗时——逐步解释如何解决数学问题比仅给出最终答案要困难得多。为说明这点，以下是两个例子，一个只有最终答案，一个有CoT。两者均来自Chun等(2024)：

Instruction: Please answer the following question. What is the boiling point of Nitrogen?

Response (without CoT): -320.4F

CoT instruction: Answer the following question by reasoning step-by-step.

The cafeteria had 23 apples. If they used 20 for lunch and bought 6 more, how many apples do they have?

Response (with CoT): The cafeteria had 23 apples originally. They used 20 to make lunch. So they had $23 - 20 = 3$. They bought 6 more apples, so they have $3 + 6 = 9$.

因此，与其他指令数据集相比，CoT数据集较为罕见。

工具使用

鉴于模型在预训练期间获取的大量知识，许多模型可能直觉上知道如何使用某些工具。然而，通过向模型展示工具使用示例，可以改进其工具使用能力。通常使用领域专家创建工具使用数据，其中每个提示是需要使用工具的任务，其回应是执行该任务所需的操作。例如，如果你想要数据来微调模型作为个人助手，你可能想问专业个人助手他们通常执行什么类型的任务，如何执行，以及需要什么工具。如果你要求人类专家解释他们如何做事，他们可能会遗漏某些步骤，要么是因为记忆错误，要么是因为他们认为这些步骤不重要。通常需要观察人类如何执行这些任务以确保准确性。

然而，对人类有效的方法可能对AI无效，反之亦然。因此，人类注释可能不适合AI代理。例如，人类可能更喜欢网页界面，而模型更容易使用API。要搜索内容，人类可能首先打开浏览器，将查询复制粘贴到搜索栏，然后点击每个结果。同时，模型可以直接向搜索API发送请求并一次处理所有结果。因此，许多人依赖模拟和其他合成技术来生成工具使用数据，这将在本章后面探讨。

工具使用数据可能还需要特殊格式。在典型的对话数据中，用户和AI轮流，每轮包含一条消息。然而，对于工具使用，AI可能需要在每轮生成多条消息，每条消息发送到不同位置。例如，它可能向代码解释器发送一条消息，向用户发送一条消息（如通知用户它在做什么）。为支持这一点，Llama 3作者(Dubey等, 2024)设计了一种多消息聊天格式，包括指定每条消息来源和目的地的消息头，以及指定人类和AI轮次开始的特殊终止标记。

在为带有对话界面的应用策划数据时，你需要考虑是否需要单轮数据、多轮数据或两者都需要。单轮数据有助于训练模型回应单个指令。而多轮数据则教导模型如何解决任务——许多现实世界任务涉及来回互动。例如，给定一个查询，模型可能需要首先澄清用户的意图，然后再解决任务。在模型回应后，用户可能提供更正或为下一步提供额外信息。

单轮数据更简单，因此更容易获取。多轮数据通常需要有目的的场景或更多涉及互动以捕捉。

数据策划不仅是创建新数据以帮助模型学习新行为，也是关于移除现有数据以帮助模型忘记不良行为。想象你在开发一个像ChatGPT这样的聊天机器人，你听到用户抱怨聊天机器人有点傲慢，

惹恼用户并浪费他们的token。例如，当用户要求它验证一个陈述是否事实正确时，聊天机器人回应：“该陈述是正确的，但其风格可以改进。”然后它继续提供一个未经请求的陈述重写。

你调查发现，在训练数据中，有几个带有未经请求建议的注释示例。你提交请求从训练数据中删除这些示例，并提交另一个请求获取演示无未经请求重写的事实检查的新示例。

每个应用可能需要不同特性的数据。不同的训练阶段也需要不同的数据混合。然而，在高层次上，数据策划遵循三个标准：数据质量、数据覆盖和数据数量。

为了让你对这些术语有直观理解，如果你将模型训练视为烹饪，输入模型的数据就是食材。数据质量相当于食材的质量——如果你的食材变质，就无法做出好食物。数据覆盖相当于拥有适当的食材组合（例如，糖不应过多或过少）。数据数量是关于你应该有多少食材。让我们详细探讨这些术语。

数据质量

少量高质量数据可能优于大量嘈杂数据，例如不相关或不一致的数据。Yi模型系列的创建者发现，10K精心制作的指令优于数十万嘈杂指令(Young等，2024)。

同样，“LIMA：对齐中的少即是多”(Zhou等，2023)显示，一个经过1,000个精心策划的提示和回应微调的65B参数Llama模型，可以产生在43%的情况下等同于或严格优于GPT-4的答案，这是由人类评估员判断的。然而，数据示例过少的缺点是LIMA不如产品级模型稳健。

Llama 3团队也得出了相同结论。值得注意的是，他们发现人类生成的数据更容易出现错误和不一致，特别是对于微妙的安全政策。这导致他们开发AI辅助注释工具以确保高数据质量。

大多数人理解数据质量的重要性，但什么是高质量数据？简短的答案是，如果数据帮助你高效可靠地完成工作，就被视为高质量。然而，对不同人来说，长答案会有所不同。一般来说，如果数据具有以下六个特征，可被视为高质量：相关性、与任务要求一致、一致性、格式正确、充分独特和合规。某些特定用例可能有其他要求：

相关性

训练示例应与你训练模型执行的任务相关。例如，如果任务是今天回答法律问题，19世纪的法律数据集可能不相关。然而，如果任务是关于19世纪的法律系统，这个数据集就高度相关。

与任务要求一致

注释应与任务要求一致。例如，如果任务需要事实一致性，注释应该事实正确。如果任务需要创造性，注释应该具有创造性。如果任务不仅需要分数还需要该分数的理由，注释应包括分数和理由。但如果任务需要简洁回答，注释应该简洁。

我使用“一致”而不是“准确”或“正确”，因为根据任务，准确或正确的回应可能不是用户想要的。

一致性

注释应在示例和注释者之间保持一致。如果你要求两个注释者注释同一个示例，他们的注释不应

相差太大。如果任务是给论文评分1至5分，两篇得分相同的论文质量是否相同？不一致的注释可能使模型困惑，使其更难学习。

拥有良好的注释指南对于获得既符合任务要求又一致的注释至关重要。

格式正确

所有示例应遵循模型预期的格式。冗余格式标记可能干扰模型学习，因此应删除。例如，如果你从网站抓取产品评论，应删除HTML标签。警惕尾随空格、新行、大小写不一致和数字格式。

充分独特

这指的是数据中的独特示例。在模型训练上下文中，重复可能引入偏见并导致数据污染。我使用"充分独特"是因为特定用例可以容忍不同程度的重复。

合规

数据应遵守所有相关内部和外部政策(包括法律和法规)。例如，如果不允许使用PII数据训练模型，你的数据不应包含任何PII数据。

在着手创建数据之前，重要的是思考这些特征对你意味着什么。本节讨论的技术旨在产生具有这些特征的数据。

数据覆盖

模型的训练数据应覆盖你期望它解决的问题范围。现实世界用户通常有各种各样的问题，他们表达这些问题的方式可能差异很大。拥有能捕捉应用多样化使用模式的数据对于模型良好表现至关重要。覆盖需要足够的数据多样性，这就是为什么许多人将此属性称为数据多样性。

例如，如果一些用户构建带有丰富参考的详细指令，而其他用户偏好简短指令，你的微调数据应包括详细和简短指令。如果用户查询通常有拼写错误，你应包括带拼写错误的示例。如果你的应用处理多种编程语言，你的训练数据应包括用户关心的编程语言。

不同应用有不同的多样性维度。例如，法语到英语的工具不需要语言多样性，但可能受益于主题、长度和说话风格的多样性。另一方面，向全球客户推荐产品的聊天机器人不一定需要领域多样性，但语言和文化多样性将很重要。

对于像聊天机器人这样的通用用例，微调数据应多样化，代表广泛的主题和说话模式。Ding等(2023)认为，进一步提高聊天语言模型性能的最直接方式是增加训练过程中使用的数据质量和多样性。为开发Nemotron(Adler等，2024)，NVIDIA研究人员专注于创建具有任务多样性、主题多样性和指令多样性的数据集，其中包括不同输出格式的指令、不同输出长度的指令，以及开放式回答和是非答案的指令。"数据添加困境"(Shen等，2024)证明在某些情况下，添加更多异质数据可能导致性能下降。

Meta分享称，Llama 3在模型架构方面与旧版Llama没有显著差异。Llama 3的性能提升"主要由数据质量和多样性的改进以及增加的训练规模驱动。"Llama 3论文详细介绍了三个训练阶段的数据

覆盖:预训练、监督微调和偏好微调。虽然本章重点关注后训练数据,但查看同一模型在所有不同训练阶段的数据混合很有用,可以比较和突出每个阶段的考虑因素。

在所有三个阶段一致的多样性轴是领域多样性, 尽管如表8-1所示, 多样化的确切含义不同。该表仅显示高级领域, 不包括更细粒度的主题, 如"几何", 这是数学中的一个子类别。后训练数据还有表中未显示的不同多样性轴, 如token数量(上下文和回应) 和轮次数。Llama 3对后训练使用合成数据, 所以另一个维度是人类生成数据与AI生成数据的比例。

表8-1. 对于Llama 3, 不同训练阶段有不同的最佳领域混合。

领域	预训练	监督微调	偏好微调
一般知识(英语)	50%	52.66%	81.99%
数学和推理	25%	21.19%	5.89%
编码	17%	14.89%	6.93%
多语言	8%	3.01%	5.19%
考试类	X	8.14%	X
长上下文	X	0.11%	X


有趣的是, 在预训练和监督微调期间, 数学、推理和代码token的总数占训练数据的近一半。虽然我不确切知道互联网数据中数学和代码的百分比是多少, 但我相信远低于50%。Llama 3作者分享说, 在小量高质量代码和数学数据上退火模型(使用逐渐减小的学习率和逐渐增加代码和数学数据训练模型)可以提升其模型在关键基准上的性能。这证实了一个普遍认为高质量代码和数学数据比自然语言文本更有效提升模型推理能力的观点。

偏好微调期间的代码和数学数据百分比要小得多(合计12.82%), 这可能是因为目标是反映用户偏好的真实分布。

这引出一个问题:我们如何决定正确的数据混合? 一种简单方法是选择准确反映真实世界应用使用情况的数据混合。你也可以使用实验找到最佳数据混合。例如, Meta执行了类似于"扩展外推"中讨论的缩放法则实验。对于每个候选数据混合, 他们在数据混合上训练了几个小模型, 并用它预测大模型在该混合上的性能。最终模型混合是从实验结果推导出的最佳猜测混合。

为评估数据多样性和质量的影响, Zhou等(2023)进行了一个有趣实验, 他们在三个相同大小的数据集上训练了一个7B参数语言模型——每个2,000个示例——但具有不同特性。第一个是高质量

但不多样化。第二个是多样化但低质量。第三个既多样化又高质量。图8-1显示了三个所得模型的生成质量。



数据数量

询问你需要多少数据就像询问你需要多少钱一样。答案因情况而异。在一个极端, Jeremy Howard和Jonathan Whitaker做了一个有趣实验, 表明LLM可以从单个示例中学习。在另一个极端, 一些团队用数百万示例微调模型。

虽然数百万示例听起来很多, 但与从头训练基础模型通常需要的数据相比很小。作为参考, Llama 2和Llama 3分别使用2万亿和16万亿token训练。如果每个示例为2,000个token, 相当于10亿和150亿个示例。

注意

你可能会想: 如果我有数百万示例, 难道不应该从头训练模型吗? 你可以并且应该评估从头训练模型是否会提高性能。虽然在预训练模型基础上微调通常比从头训练更高效, 但在某些情况下微调可能更糟, 特别是当你有大量训练数据时。这是由于一种称为钙化的现象, 预训练可能钙化(即冻结)模型权重, 使它们不能很好地适应微调数据(Hernandez等, 2021)。较小模型比较大模型更容易受到钙化影响。

除了数据质量和数据多样性外, 有三个其他因素影响你需要多少数据:

微调技术

完全微调承诺提供最佳性能，但比PEFT方法如LoRA需要多得多的数据。如果你有数万到数百万对(指令, 回应), 你可能想尝试完全微调。如果你只有几百或几千示例, PEFT可能效果最好。


任务复杂性

简单任务, 如分类产品评论是正面还是负面, 需要的数据远少于复杂任务, 如关于财务报告的问答。

基础模型的性能

基础模型越接近理想性能, 需要的示例就越少。假设更大的基础模型更好, 你可能需要更少的示例来微调大模型。这与预训练相反, 预训练中更大的模型需要更多训练数据。

OpenAI的微调指南显示, 如果你有较少示例(100个), 更先进的模型会给你更好的微调性能。这可能是因为更先进的模型开箱即用就表现更好。然而, 在大量示例(550,000个)微调后, 实验中的所有五个模型表现相似, 如图8-2所示。



简而言之, 如果你有少量数据, 你可能想在更先进模型上使用PEFT方法。如果你有大量数据, 在较小模型上使用完全微调。

在投资策划大型数据集之前, 你可能想从一个小而精心制作的数据集(例如50个示例)开始, 看看微调是否能改进模型。如果这个小数据集足以达到理想性能, 那很好。明显改进表明更多数据会进一步提高性能。如果在小数据上没有观察到改进, 更大的数据集很少能解决问题。

然而，在得出微调小数据集不能改进模型的结论前要小心。除了数据外，许多因素可能影响微调结果，如超参数选择（例如学习率过高或过低）、数据质量、提示设计不佳等。在绝大多数情况下，你应该在使用50-100个示例微调后看到改进。

提示

可以通过首先使用较低质量或相关性较低的数据微调模型，来减少所需的高质量数据量。以下是这种方法的三个例子：

自监督 → 监督

你想微调一个回答法律问题的模型。你的（问题，答案）集很小，但你有许多法律文档。你可以首先以自监督方式在法律文档上微调模型，然后在（问题，答案）对上进一步微调模型。

相关性较低的数据 → 相关数据

你想微调一个为产品评论分类情感的模型，但你的产品情感数据较少，而推文情感数据较多。你可以首先微调模型分类推文情感，然后进一步微调它分类产品情感。

合成数据 → 真实数据

你想微调一个从医疗报告预测医疗状况的模型。由于任务的敏感性，你的数据有限。你可以使用AI模型合成大量数据首先微调模型，然后在真实数据上进一步微调。这种方法更难正确实施，因为你需要完成两个不同的微调工作并协调它们之间的过渡。如果你不知道自己在做什么，可能最终使用更多计算资源却产生比仅用高质量数据微调更差的模型。

实验小数据集可以帮助估计你需要多少额外数据。你可以在当前数据集的子集上微调模型——例如25%、50%、100%——并绘制性能如何随数据集大小扩展。随着数据集大小增加，性能增益曲线陡峭意味着你可以通过翻倍数据量获得显著性能提升。平稳曲线意味着翻倍数据只会带来较小的改进。图8-3显示了这种图表的例子。

Performance vs. Dataset size





图8-3所示的性能增益曲线相当典型。在大多数情况下，额外的训练示例产生递减回报：随着数据集增长，相同数量的示例通常带来更低的性能提升。例如，前1,000个示例可能将模型准确率提高十个百分点，但接下来的1,000个示例可能只提高五个百分点。

虽然更多的微调示例通常会提高模型性能，但示例的多样性也很重要。论文“扩展指令微调语言模型”(Chung等, 2022)显示，当微调任务数量从9增加到282时，模型性能显著提升。超过282个任务后，性能增益开始平稳，尽管在增加到1,836个任务时仍有积极但递增的改进，如图8-4所示。这表明模型在微调期间从接触多样化任务集中获益很大。

数据多样性可以体现在任务类型(如摘要和问答)、主题多样性(如时尚、金融和技术)以及预期输出格式(如JSON输出或是非答案)。



微调使用多少数据不仅取决于你的需求，还取决于你能负担多少。如果你为数据注释预算10,000美元，每个示例成本2美元，你最多可以有5,000个示例。你可能还需要平衡数据和计算的预算。在数据上花更多钱意味着你在计算上的钱更少，反之亦然。

数据获取和注释

数据获取的目标是生成一个具有你需要的质量和多样性的足够大的数据集，同时确保你的数据实践尊重用户隐私并遵守法规。数据获取涉及通过各种方法收集数据，如获取公共数据、购买专有数据、注释数据和合成数据。数据获取策略是一个小众但不断发展的研究领域：在给定预算下，如何最好地获取满足特定要求的数据集。

然而，最重要的数据源通常是来自你自己应用的数据。如果你能找到一种方法创建数据飞轮，利用用户生成的数据不断改进你的产品，你将获得重大优势。应用数据是理想的，因为它完全相关

并与你的任务一致。换句话说，它匹配你关心的数据分布，这在其他数据源中很难实现。用户生成的数据可以是用户内容、用户使用产生的系统生成数据或用户反馈。如何设计用户反馈系统将在第10章讨论。

在投资创建自己的数据之前，首先检查可用数据集。数据市场广泛，提供开源和专有数据。如果幸运，其中一些可能正是你需要的。然而，通常是混合搭配方法。数据集可以通过多个获取渠道从多个数据源开发。例如，创建(指令，回应)数据集的过程可能如下：

1. 找到具有理想特性的可用数据集。你可能找到一个有10,000个示例的有前途数据集。
2. 删除低质量指令。假设这剩下9,000个示例。
3. 留出低质量回应的指令。假设你发现3,000个这样的示例。这剩下6,000个高质量指令和高质量回应的示例。
4. 为3,000个高质量指令手动编写回应。现在你的数据集总共有9,000个高质量示例。
5. 意识到主题X的数据不足，手动创建100个关于X的指令模板。使用AI模型使用这些10个模板合成2,000个指令。
6. 手动注释这些2,000个合成指令。现在你的数据集总共有11,000个示例。

当然，这是对实际数据集策划过程的过度简化，大多数步骤为了节省篇幅并避免读者厌烦而隐藏。例如，可能有几个步骤中你意识到许多注释不够有用，所以必须更新注释指南并重新注释数据。更糟的是，你可能发现其中一些在事实上不正确，所以你必须雇用另一组注释员来核查原始注释的事实。或者你可能发现每个模板100个合成指令会损害数据多样性，所以你必须创建更多模板并为每个模板生成更少的指令。依此类推。

公开可用数据集的资源

以下是一些可以寻找公开可用数据集的资源。虽然你应该利用可用数据，但绝不要完全信任它。数据需要彻底检查和验证。

在使用数据集前始终检查其许可证。尽量了解数据来源。即使数据集有允许商业使用的许可证，其中部分可能来自不允许的源：

1. Hugging Face和Kaggle各自托管数十万个数据集。
2. Google有一个很棒但被低估的数据集搜索。
3. 政府通常是开放数据的良好提供者。Data.gov托管数十万个数据集，data.gov.in托管数万个。

4. 密歇根大学社会研究所ICPSR拥有来自数万社会研究的数据。
5. 加州大学欧文分校的机器学习存储库和OpenML是两个较老的数据集存储库，各自托管数千个数据集。
6. 开放数据网络让你可以在数万个数据集中搜索。
7. 云服务提供商通常托管少量开放数据集；最著名的是AWS的开放数据。
8. ML框架通常有小型预构建数据集，可在使用框架时加载，如TensorFlow数据集。
9. 一些评估工具托管评估基准数据集，这些数据集足够大用于PEFT微调。例如，Eleuther AI的lm-evaluation-harness托管400多个基准数据集，平均每个2,000多示例。
10. 斯坦福大型网络数据集集合是图数据集的良好存储库。

通常，你可能需要注释自己的微调数据。注释不仅因注释过程而具有挑战性，也因创建明确注释指南的复杂性而具有挑战性。例如，你需要明确说明什么是好的回应，是什么使它良好。回应可以正确但无用吗？得分3和4的回应有什么区别？手动和AI驱动的注释都需要注释指南。

一些团队，包括LinkedIn，报告说注释指南是其AI工程管道中最具挑战性的部分之一。令人担忧的是，人们常常因所需时间和精力而半途放弃仔细注释，希望他们的模型能自行找出正确回应。许多模型足够强大，偶尔能成功，但对许多应用来说，依赖模型找出答案可能风险太大。

好消息是，这些指南与评估数据的指南相同，如第4章所讨论。这是另一个应该投入更多时间策划评估指南和数据的论点。如果幸运，你的评估示例可以增强或用作种子示例来合成新数据。下一节我们将讨论如何做到这一点。

数据增强和合成

与计算和人才一起，数据是AI最大的挑战。能够以编程方式生成数据一直是整个行业的长期目标。两个常用的过程是数据增强和数据合成：

数据增强从现有数据（真实的）创建新数据。例如，给定一张真实的猫图像，你可以翻转它创建同一只猫的新图像。

数据合成生成数据以模仿真实数据的属性。例如，你可以模拟鼠标如何在网页上移动，以生成机器人运动数据。

换句话说，增强数据源自真实数据，而合成数据不是真实的。然而，由于两者的目标都是自动化数据创建，有时这两个术语可以互换使用。在本章中，我将经常使用数据合成来指代两者。

人工生成的数据在软件工程中有很长历史。它最初用于为测试目的生成假数据。例如，像Faker和Chance这样的库让你生成简单格式的数据，如姓名、地址、电话号码和电子邮件地址进行测试。假设你已经构建了一个解析送货地址的程序。你可以使用假数据生成器生成不同国家和州的不同格式地址，确保你的程序可以解析所有这些。

随着AI能够生成与人类生成的数据无法区分的数据，现在可以合成更复杂的数据，如医生笔记、合同、财务报表、产品说明、图像、视频广告等。这使得生成数据更容易并启用更多合成数据用例。

虽然合成数据承诺显著减轻对人类生成数据的压力，但合成数据不能完全替代人类数据。在许多用例中，如"AI生成数据的限制"中讨论的，混合人类和AI生成的数据通常产生最佳价值。

为什么需要数据合成

合成数据因许多原因而有吸引力。你可以合成数据以改进黄金数据三要素：数量、覆盖和质量。你还可以合成数据以缓解隐私问题和蒸馏模型：

增加数据数量

数据合成的最大原因是它允许你大规模生产数据，承诺为训练和测试AI模型提供丰富数据供应。理论上，更多数据有助于模型泛化到更广泛的任務。这对于真实世界数据稀缺或难以获取的情况特别有用，如罕见天气条件的数据、深海探索数据或涉及自动驾驶汽车事故的数据。

增加数据覆盖

你可以生成具有目标特性的数据以提高模型性能或使模型表达特定行为。例如，你可以生成非常短的文本或非常长的文本。你可以为有毒检测模型创建包含有毒短语的对话。反之，如果真实世界数据有毒，你可以合成安全数据。使用AI合成对抗性示例特别常见。也可以为稀有类别生成数据以解决类别不平衡的挑战。如"TrueTeacher"所述，Gekhman等(2022)使用LLM生成事实不一致的摘要，然后用于训练模型检测事实不一致性。

在他们的论文"通过模型编写的评估发现语言模型行为"(Perez等，2022)中，Anthropic讨论了各种数据合成技术，以生成能测试154种不同AI行为的特定数据集，包括个性特征、政治观点、道德立场和社会偏见。他们发现，在LM(语言模型)生成和人类生成的数据集之间的一对一比较中，"LM编写的数据集接近人类编写的質量，有时甚至超过它们。"

换句话说，你可以使用合成数据增加数据覆盖：生成目标数据覆盖现有数据不足的领域。

提高数据质量

尽管普遍认为合成数据通常质量低于人类生成的数据，但有时情况相反。有时，人类可能有基本限制，导致人类生成的数据质量低于AI生成的数据。一个例子是前面讨论的工具使用数据——人类和AI有根本不同的操作模式和工具偏好。另一个例子是生成复杂数学问题——AI可以生成远比普通人类专家构想的更复杂的问题。

一些团队也更喜欢使用AI生成偏好数据。虽然每个人在偏好上可能有些一致，但不同人之间的表现往往差异很大，不仅受个人偏好影响，还受情绪和动机影响。相比之下，AI生成的偏好评分可能更一致可靠。

缓解隐私问题

合成数据通常是你因隐私问题而无法使用人类生成数据的用例的唯一选择。例如，在医疗保健中，立法使得使用真实患者记录训练模型变得困难甚至不可能，你可以生成不包含任何敏感信息的合成患者记录。在保险中，你可以使用合成索赔而不是使用包含敏感个人和财务信息的真实索赔。

蒸馏模型

有时，你可能想训练一个模型模仿另一个模型的行为。目标通常是创建一个与原始模型性能相当的更便宜和/或更快的模型(蒸馏模型)。这是通过使用原始模型生成的数据训练蒸馏模型来完成的。

这只是人们转向数据合成的许多原因中的五个。由于其不可否认的吸引力，越来越多的模型使用合成数据进行训练，越来越多的技术被开发用于合成数据。

传统数据合成技术

数据合成并非AI独有。它在软件测试、游戏和机器人技术中有着悠久历史。使用算法生成数据也称为程序生成，与手动生成相对。程序生成常用于游戏中即时生成内容，如关卡、地图、物品和角色。这些行业中使用的大多数数据生成技术都可应用于AI。

传统上，数据合成和增强的两种方法是基于规则和模拟。由先进AI模型实现的较新方法是使用AI本身合成数据。本节在转向下一节的AI驱动数据合成之前，快速概述这两种传统技术。

基于规则的数据合成

生成数据最简单的方法是使用预定义规则和模板。例如，要创建信用卡交易，从交易模板开始，使用像Faker这样的随机生成器填充模板中的每个字段：

```
An example of a transaction template.
Transaction ID: [Unique Identifier]
Date: [MM/DD/YYYY]
Time: [HH:MM:SS]
Amount: [Transaction Amount]
Merchant Name: [Merchant/Store Name]
Merchant Category: [Category Code]
Location: [City, State, Country]
Payment Method: [Credit Card/Debit Card/Cash/Online Payment]
Transaction Status: [Completed/Pending/Failed]
Description: [Transaction Description]
```

由于交易数据的敏感性，许多欺诈检测模型首先在从这样的模板生成的合成交易数据上训练，以证明其可行性，然后才获得真实数据访问权。

使用模板生成遵循特定结构的文档很常见，如发票、简历、税表、银行对账单、活动议程、产品目录、合同、配置文件等。模板也可用于生成遵循特定语法和句法的数据，如正则表达式和数学方程。你可以使用模板生成数学方程让AI模型解决。DeepMind使用1亿个合成示例训练了一个奥林匹克级几何模型AlphaGeometry(Trinh等，2024)。

你可以通过应用简单转换从现有数据程序生成新数据。对于图像，你可以随机旋转、裁剪、缩放或擦除图像的一部分。猫的翻转图像仍应是猫。足球比赛的略微裁剪图像仍应是足球比赛。Krizhevsky等(2012)在他们具有传奇色彩的AlexNet论文中通过使用它来增强ImageNet数据集(Deng等，2009)展示了这种技术的有用性。

对于文本，你可以随机用类似词替换某个词，假设这种替换不会改变句子的含义或情感。例如，原始句子"她是一名出色的护士"可以生成一个新示例："她是一名优秀的护士"。

这种方法可用于减轻数据中的潜在偏见。如果你担心数据中存在性别偏见，例如"护士"这个词与女性相关联而"医生"这个词与男性相关联，你可以用其反义词替换通常带有性别的词，如将"她"替换为"他"，如表8-2所示。

表8-2. 数据增强可以帮助减轻数据中的某些偏见。

原始数据	增强数据
她是一名出色的护士。	他是一名出色的护士。
	她是一名出色的医生。
公司的CEO, 王先生, ...	公司的CEO, 王女士, ...
今天, 我妈妈做了砂锅晚餐。	今天, 我爸爸做了砂锅晚餐。
Emily一直喜欢小提琴。	Mohammed一直喜欢小提琴。

类似词可以通过同义词词典或在词嵌入空间中找到嵌入彼此接近的词。你可以超越简单的词替换，要求AI重新表述或翻译示例，我们稍后会讨论。

一个有趣的转换是扰动：向现有数据添加噪声以生成新数据。最初，研究人员发现稍微扰动数据样本可以欺骗模型错误分类。例如，向船的图片添加白噪声可能导致模型将其误分类为汽车。论文"欺骗深度神经网络的单像素攻击"(Su等，2017)显示，Kaggle CIFAR-10测试数据集中67.97%的自然图像和ImageNet测试图像中16.04%可以通过改变一个像素被错误分类。如果被利用，这构

成严重风险。攻击者可能欺骗AI模型将其误认为授权员工，或使自动驾驶汽车错将分隔带误认为车道，导致事故。

你可以在扰动数据上训练模型。扰动既可以提高模型性能，又可以使其更能抵抗攻击；参见Goodfellow等，2013和Moosavi-Dezfooli等，2015）。2019年，Hendrycks和Dietterich通过对ImageNet图像应用15种常见视觉损坏，如改变亮度、添加雪、改变对比度和添加噪声，创建了ImageNet-C和ImageNet-P。

扰动也可用于文本。例如，为训练BERT，作者将1.5%的token替换为随机词(Devlin等，2018)。他们发现这种扰动导致小幅性能提升。

视觉数据可以使用更复杂的算法增强。Snap(2022)有一个很好的案例研究，说明他们如何增强资产以创建未表示的边缘案例并减轻数据中的隐含偏见。给定一个角色，他们合成类似角色，但具有不同肤色、体型、发型、衣服，甚至面部表情。这些增强资产然后用于训练AI模型。

模拟

与在真实世界收集数据的实验相比，这可能昂贵且危险，你可以虚拟模拟这些实验。例如，要测试自动驾驶汽车在高速公路上遇到马时的反应，在高速公路上释放真马会很危险。相反，你在虚拟环境中模拟这种情况。自动驾驶模拟引擎的例子包括CARLA(Dosovitskiy等，2017)、Waymo的SimulationCity和特斯拉的旧金山模拟。

同样，在虚拟环境中模拟机器人训练数据非常常见。假设你想训练机器人倒咖啡，但你不确切知道每个关节应如何移动才能成功。你可以模拟多种场景，使用不同关节运动，并只使用成功倒咖啡的场景训练机器人。

模拟允许你以最小成本运行多个实验，同时避免事故和物理损坏。在模拟中工作的机器人可能在现实世界中不起作用，但如果它在模拟中失败，它可能在现实世界中也会失败。然而，无论你的模拟多么复杂，它们都是对现实世界的简化。Sim2Real是一个专注于将在模拟中训练的算法适应到现实世界的子领域。

模拟常用于生成教导模型使用工具的数据。如前所述，人类生成的操作可能并不总是对AI代理最有效。模拟可能帮助发现人类忽视的操作。给定查询，你可以模拟不同操作序列，执行这些序列并验证其结果。最有效的操作序列然后用作该查询的注释回应。

模拟对于生成罕见事件的数据特别有价值。例如，在金融中，研究人员可以模拟公司成功上市或重大破产等场景，了解其市场影响。制造商可以模拟材料或装配中的缺陷，生成数据来训练异常检测和质量控制模型。同样，通过模拟地球系统，气候科学家可以创建温度变化、降水模式和极端天气场景的变化。这些合成数据然后馈入AI模型，使其能够从更广泛的可能未来中学习。

基于规则和基于模拟的技术对许多用例都很有用，但直到AI能够生成真实和高质量的数据，数据合成才真正起飞。接下来让我们看看这些方法。

AI驱动的数据合成

就像人类生成数据的方式几乎无限一样，AI也可以通过许多方式生成数据。这里讨论的技术并非全面，但应该给你一个良好概述。

强大的AI模型为模拟开辟了许多新可能性。AI可以模拟任意程序的结果。例如，"StableToolBench"(Guo等, 2024)展示了如何使用AI模拟API而无需调用它们。想象你想训练一个与一组API交互的模型。你可以使用AI模型模拟这些调用的预期结果，而不是进行实际API调用，这可能代价高昂或缓慢。

AI可以模拟人类。例如，想象你想训练一个下棋机器人。人类玩的游戏可能需要太长时间。与AI玩家的比赛会快得多。为训练其Dota 2机器人，OpenAI使用了一个模拟器，使机器人每天可以玩大约180年的游戏量。机器人通过自我对弈学习，这种方法称为自我对弈，帮助它随着时间发展和改进策略(OpenAI, 2019)。同样，DeepMind使用自我对弈收集数百万围棋比赛的数据来训练AlphaGo(Silver等, 2016)。

自我对弈不仅对游戏机器人有用，对一般代理也有用。你可以让AI互相谈判，使用不同策略，看哪个更有效。你可以让模型的一个版本扮演有问题的客户，另一个扮演客户支持代理。

AI的释义和翻译能力可用于增强现有数据集。例如，给定查询"如何重置密码？"，AI可以释义它创建三个新查询：

- "我忘记了密码。"
- "如何更改密码？"
- "重置密码的步骤。"

Yu等(2023)以不同方式重写了MATH和GSM-8K中的15,000个示例，创建了MetaMath，一个近400,000个示例的新数据集。他们表明，在这个新数据集上训练的模型在相关数学基准上优于更大的模型。

使用AI将高资源语言(在线更多可用)的数据翻译成低资源语言以帮助训练低资源语言模型很常见。这对训练专门用于低资源语言如克丘亚语或老挝语的小型模型很有用。

你可以通过回译验证翻译质量。假设原始英语句子是X，翻译的老挝语句子是Y。你可以使用另一个模型将翻译翻译回原始语言，X'，然后比较X'与原始句子X。如果它们非常不同，翻译Y可能不好。

AI可以翻译不仅是自然语言还有编程语言。你可以使用AI将用一种语言编写的代码翻译成另一种。Llama 3作者使用了他们SFT数据集的代码翻译，包括更广泛的编程语言。事实上，Llama 3的训练严重依赖合成数据，作者使用了许多创造性技术生成有用数据。

例如，他们使用回译生成代码解释和文档。从代码片段开始，他们使用AI生成解释和文档。然后再次使用AI从解释和文档生成代码片段。只有当生成的代码被认为忠于原始代码时，解释和文档才会用于微调模型。

AI可以为预训练和后训练生成数据，尽管合成数据在后训练中比在预训练中更有意图地包含。一个可能的解释是预训练的目标是增加模型的知识，虽然AI可以合成不同格式的现有知识，但合成新知识更难。

然而，随着互联网充斥AI生成内容，依赖互联网数据的模型可能已经在合成数据上预训练。也有合成数据集如Cosmopedia(Allal等, 2024)，一个250亿token的合成教科书、博客文章、故事、帖子和WikiHow文章集合，由Mixtral-8x7B-Instruct-v0.1生成(Jiang等, 2024)。

后训练数据合成也更常见，因为后训练数据，包括指令数据和偏好数据，通常需要最多努力生成。使用AI选择几个回应中的更好回应更直接——经过第3章已涵盖的内容。以下部分将重点关注如何使用AI合成用于监督微调的指令数据。

指令数据合成

在指令微调期间，每个示例包括一个指令和一个回应。AI可用于合成指令、回应或两者。例如，你可以使用AI生成指令，人类编写回应。你也可以使用人类编写指令，AI生成回应：

- 对于指令生成，为确保你生成足够的指令覆盖你的用例，你可以从你想在数据集中包含的主题、关键词和/或指令类型列表开始。然后，对于列表中的每一项，生成一定数量的指令。你也可以从一组模板开始，为每个模板生成一定数量的示例。请注意，主题列表和模板都可以由AI生成。
- 对于回应生成，你可以为每条指令生成一个或多个回应。

例如，为创建UltraChat(Ding等, 2023)，一个多轮对话数据集，作者首先要求ChatGPT生成30个关于我们日常生活各个方面的主题，如技术、食物和饮料、时尚、自然、教育、金融、旅行等。对于每个主题，他们要求ChatGPT生成30到50个子主题。然后作者使用同一模型为这些子主题生成指令和相应回应。

同样，为训练Alpaca(Taori等, 2023)，斯坦福研究人员从Self-Instruct种子数据集(Wang等, 2022)的175个(指令，回应)示例开始。这些示例最初编写用于覆盖多样且有趣的用途范围。Alpaca作者然后使用GPT-3模型text-davinci-003生成52,000对(指令，回应)来模仿这些种子示例，如图8-5所示。

Example seed task

Instruction: Brainstorm a list of possible New Year's resolutions.

Output:

- Lose weight
- Exercise more
- Eat healthier

Example generated task

Instruction: Brainstorm creative ideas for designing a conference room.

Output:

... incorporating flexible components, such as moveable walls and furniture ...

还有许多创造性方法合成具有特定特性的指令数据。例如，就像人类编写长内容比短内容更难一样，AI生成高质量长回应比短指令更难。回应越长，AI出现幻觉的机会越大。如果我们使用人类生成的回应和AI生成的指令怎么样？一些研究者，如Köksal等(2023)、Li等(2023)和Chen等(2023)，遵循反向指令方法：取现有长篇、高质量内容如故事、书籍和维基百科文章，使用AI生成会引出这些内容的提示。这产生更高质量的指令数据，避免AI生成回应中的幻觉。

可以使用反向指令开发越来越强大的模型，而无需添加手动注释数据。Li等(2023)展示了这是如何工作的：

1. 从少量种子示例开始训练一个弱模型。
2. 使用这个弱模型为现有高质量内容生成指令，创建高质量指令数据。
3. 用这个新的高质量指令数据微调弱模型。
4. 重复直到达到理想性能。

一种创造性方法是使用合成数据微调模型以理解更长上下文。例如，如果你当前的模型处理最多8K tokens，但你希望它处理128K tokens，长上下文微调过程可能如下：

1. 将长文档拆分为更短块（例如，低于8K tokens）。
2. 为每个短块生成几对(问题，答案)。
3. 对于每对(问题，答案)，使用原始长文档，可能超过8K tokens但短于你的目标长度，作为上下文。这训练模型使用扩展上下文回答问题。

Llama 3论文(Dubey等, 2024)的详细程度使其成为指令数据合成的优秀案例研究。我已经提到Llama 3合成数据的两种方式：代码翻译和代码回译。这两种方法都从现有代码片段生成更多数据。然而，作者还使用AI从头合成编码指令数据，使用以下工作流：

1. 使用AI生成涵盖多样主题范围的大量编程问题描述。
2. 给定问题描述和编程语言，生成解决方案。Dubey等发现，包括良好编程的一般规则和CoT推理有助于提高回应质量。

为确保生成数据的质量，他们采用了严格的正确性分析和错误修正管道：

1. 通过解析器和代码检查器运行生成的代码，捕获语法错误，如缺少导入和未初始化变量。
2. 使用单元测试捕获运行时执行错误。有趣的是，他们使用AI生成这些单元测试。
3. 当解决方案在任何步骤失败时，提示模型修改代码。提示包括原始问题描述、有缺陷的解决方案，以及来自解析器、代码检查器和单元测试的反馈。只有通过所有检查的示例才会包含在最终监督微调数据集中。

结合这三种方法——代码翻译、代码回译和代码生成——Llama 3的数据合成工作流相当令人印象深刻。总结一下，这三种方法如何一起工作：

1. 使用AI生成问题描述。
2. 使用AI为每个问题在不同编程语言中生成解决方案。
3. 使用AI生成单元测试测试生成的代码。

4. 提示AI修复合成代码中的错误。
5. 使用AI将生成的代码翻译成不同编程语言。筛选出未通过测试的翻译代码。
6. 使用AI生成关于代码的对话，包括代码解释和添加文档。筛选出未通过回译验证的生成解释和文档。

使用这个管道，Dubey等能够为Llama 3.1的监督微调生成超过270万合成编码相关示例。

数据验证

考虑到数据质量对模型性能的重要性，我们必须有方法验证数据质量。AI生成数据的质量可以用评估其他AI输出的相同方式衡量——通过功能正确性和AI评判。

虽然本节重点关注合成数据，但大多数技术可用于评估训练数据一般质量。

回想第4章中评估驱动开发的概念，公司更可能创建他们能评估的应用。同样，人们倾向于合成他们可以验证的数据。编码是最受欢迎的基础模型用例之一，因为它可以功能性评估，出于同样原因，编码相关示例是最常被合成的数据。训练Llama 3的合成数据大部分与编码相关。作者用于合成数据的三种方法都产生可以通过代码执行和回译以编程方式验证的数据。

对于无法通过功能正确性验证的合成数据，通常使用AI验证器。AI验证器可以是通用AI评判或专门评分器。有许多方式构架验证问题。最简单形式中，AI验证器可以为每个生成的示例分配1至5分或将每个示例分类为好或坏。你也可以向基础模型描述质量要求并指导模型确定数据示例是否满足这些要求。

如果你关心数据的事实一致性，可以使用第4章讨论的事实不一致性检测技术筛选出可能包含幻觉的示例。

根据用例和生成的数据，你也可以创新。例如，如果你希望合成数据模仿真实数据，其质量可以通过区分两者的难度来衡量。你可以训练AI内容检测器识别AI生成的数据——如果容易区分真实和合成数据，则合成数据不好。或者，如果你希望合成数据类似高质量学术工作，你可以训练分类器预测生成的论文是否会被像NeurIPS（神经信息处理系统会议和研讨会）这样的著名会议接受，并丢弃预测为明显拒绝的论文。

你可以让模型检测每个生成示例的主题，然后删除主题与你的任务不相关的示例。如果你期望所有数据遵循类似模式，也可以使用异常检测识别离群值——离群示例可能质量低。

就像真实数据一样，合成数据也可以使用启发式方法过滤。一般来说，你可能想删除对你的应用来说空或太短的示例。如果示例太长，你可能想截断或删除它。你可以按关键词、用户/作者、创建日期、元数据或来源过滤数据。例如，Self-Instruct作者(Wang等, 2022)使用以下启发式方法过滤生成的示例：

- 重复性示例
- 太长或太短的指令
- 具有相同指令但不同回应的示例

- 输出是输入重复的示例

尽管有许多技术评估合成数据，评估仍然具有挑战性。与其他AI应用一样，AI生成数据的最终质量测试是其现实世界性能——它是否能提高模型性能——对许多模型来说，合成数据已经通过了这一测试。

AI生成数据的限制

考虑到合成数据的日益有用，令人兴奋的是想象可能永远不必担心人类注释数据的可能性。然而，虽然合成数据的作用肯定会随着时间的推移继续增长，但AI生成的数据可能永远不会完全取代人类生成的数据。原因很多，但四个主要原因是质量差异、模仿限制、潜在的模型崩溃以及AI数据生成如何掩盖其血统。

质量控制

AI生成的数据可能质量低，正如人们不厌其烦地说，“垃圾进，垃圾出。”如前所述，如果人们无法验证其质量，他们会犹豫使用合成数据。能够开发可靠方法和指标评估数据将是使合成数据更有用的关键。

表面模仿

如“模仿专有LLM的虚假承诺”(Gudibande等, 2023)所警告，通过模仿获得的表现性能可能是表面的。这项研究表明，模仿模型善于模仿教师模型的风格，但可能在事实准确性和泛化到训练数据之外的任务方面挣扎。

更糟的是，模仿可能迫使学生模型产生幻觉。想象一下，如果教师模型能够回答复杂数学问题，因此其对这些问题的回应是解决方案。在这些解决方案上训练学生模型实际上教导它产生看起来像解决方案的答案，即使学生模型无法解决这些问题。Gudibande等(2023)建议，为提高推理能力，我们需要专注于提高基础模型的质量。

潜在的模型崩溃

还不清楚模型可以在多少AI生成数据上训练。一些研究表明，递归使用AI生成数据训练会导致所得模型不可逆的缺陷，随着时间的推移降低其性能。在“递归的诅咒：在生成数据上训练使模型忘记”中，Shumailov等(2023)将这种现象命名为模型崩溃，并证明其在包括变分自编码器、高斯混合模型和LLM等模型中的出现。模型崩溃可能在预训练和后训练期间发生。

一种可能的解释是，AI模型更可能生成概率高的事件（例如，没有癌症）而不是概率低的事件（例如，有癌症）。经过多次迭代，概率高的事件在生成的数据中变得过度表示，而概率低的事件变得表示不足。这导致模型随着时间的推移输出更多常见事件，同时忘记罕见事件。

在“模型崩溃是否不可避免？”中，Gerstgrasser等(2024)认为，虽然如果整个训练数据集是合成的，模型崩溃是不可避免的，但可以通过将合成数据与真实数据混合来避免。Bertrand等(2023)和Dohmatob等(2024)显示类似结果。然而，这些论文都没有对合成数据与真实数据的比例给出明确建议。

一些人已能够使用大量合成数据改进模型性能。例如, "普通7B语言模型已经拥有强大的数学能力"(Li等, 2024)证明, 合成数据在数学问题上微调Llama 2-7B模型方面几乎与真实数据一样有效。在他们的实验中, 当扩展到大约一百万个样本时, 合成数据没有显示明显饱和。同样, Nemotron-4 340B-Instruct(NVIDIA, 2024)在其指令微调 and 偏好微调阶段使用了98%的合成数据。然而, 这些实验只进行了一次模型迭代。

AI生成的数据也可能延续偏见。"数据反馈循环: 模型驱动的数据集偏见放大"(Taori和Hashimoto, 2023)证明, 当模型在包括先前模型输出的数据集上训练时, 模型中任何现有偏见都可能被放大。作者发现, 模型输出越忠实于原始训练分布的特性, 反馈循环越稳定, 从而最小化偏见放大的风险。

掩盖数据血统

AI生成数据的这一限制更微妙。AI生成掩盖了数据血统。AI模型受其训练数据影响, 有时可能在用户不知情的情况下重复它。这造成风险。假设你使用模型X生成数据来训练你的模型。如果模型X在具有版权侵犯的数据上训练, 你的模型也可能侵犯版权。

或者想象你然后使用基准B评估你的模型, 显示强大性能。然而, 如果模型X也在基准B上训练, 你在B上的结果被污染。没有明确的数据血统, 很难评估模型的商业可行性或信任其性能。

我们已经讨论了如何使用AI生成数据以及如何评估生成的数据及其限制。在下一节中, 让我们转向一种特殊的数据合成用例, 其中AI生成的数据不仅是补充的而且是必需的: 模型蒸馏。

模型蒸馏

模型蒸馏(也称为知识蒸馏)是一种小模型(学生)被训练模仿更大模型(教师)的方法(Hinton等, 2015)。大模型的知识被蒸馏到小模型中, 因此术语蒸馏。

传统上, 模型蒸馏的目标是生产用于部署的较小模型。部署大模型可能资源密集。蒸馏可以生产较小、更快的学生模型, 保持与教师相当的性能。例如, DistilBERT, 一个从BERT蒸馏的模型, 将BERT模型大小减少40%, 同时保留97%的语言理解能力并快60%(Sanh等, 2019)。

学生模型可以像DistilBERT一样从头训练, 或者像Alpaca一样从预训练模型微调。2023年, Taori等在由text-davinci-003(一个1750亿参数模型)生成的示例上微调了Llama-7B(Llama的70亿参数版本)。得到的模型Alpaca的行为类似于text-davinci-003, 同时只有教师模型大小的4%。

注意

并非所有模型都可以蒸馏。许多模型许可证禁止使用其输出训练其他模型, 特别是训练竞争模型。

合成指令数据通常与基于适配器的技术一起使用, 如LoRA。例如, BuzzFeed使用LoRA和由OpenAI的text-davinci-003生成的示例微调了Flan-T5模型。得到的模型将他们的推理成本降低了80%, 尽管模型表现如何不清楚(2023)。

请注意，并非所有使用合成数据的训练都是模型蒸馏。模型蒸馏意味着教师模型的性能是学生的黄金标准。然而，可以使用合成数据训练比教师更大更强大的学生模型。

前一节讨论的反向指令模型引导(Li等, 2023)就是一个例子。另一个例子是NVIDIA的Nemotron-4。NVIDIA研究人员团队首先预训练了一个3400亿参数基础模型。然后使用由Mixtral-8x7B-Instruct-v0.1(Jiang等, 2024)(一个560亿参数混合专家模型)生成的指令和偏好数据微调该基础模型。得到的学生模型Nemotron-4-340B-Instruct在各种任务上优于教师模型(NVIDIA, 2024)。

Llama 3论文指出，虽然在由更能干模型生成的数据上训练可以显著提高模型性能，但不分青红皂白地在自生成数据上训练不会提高模型性能，甚至可能降低它。然而，通过引入机制验证合成数据质量并只使用验证过的合成数据，他们能够使用其生成的数据持续改进模型。

数据处理

数据需要根据每个用例的要求进行处理。本节讨论一些数据处理步骤作为参考。

我发现阅读披露其数据集细节的模型论文很有帮助，因为它们通常包含研究人员如何策划、生成和处理数据的很好提示。

提示

处理大量数据时，这些处理步骤中的每一个都可能需要数小时甚至数天。帮助优化过程效率的提示包括：


- 你可以按节省时间和计算的顺序执行这些数据处理步骤。例如，如果清理每个示例比去重数据需要更多时间，你可能想先删除重复示例然后再清理它们。但如果去重比过滤低质量数据需要更多时间，先过滤低质量数据。
- 总是进行试运行验证你的处理脚本按预期工作，然后再应用到所有数据。
- 避免就地更改数据。考虑保留原始数据副本，原因有二：
 - 你或另一个团队可能需要以不同方式处理数据用于其他应用。
 - 脚本中的错误可能会破坏你的数据。

检查数据


假设在梳理公共和内部数据后，你已收集了原始数据集。首先要做的是检查数据以了解其质量。获取数据的信息和统计数据。数据来自哪里？它是如何处理的？它还用于什么其他用途？

绘制token分布图(看哪些token常见)、输入长度、回应长度等。数据使用任何特殊token吗？你能获得数据中主题和语言的分布吗？这些主题和语言与你的任务有多相关？

你可以创造性地使用统计数据了解你的数据。例如，一组微软研究人员(2023)使用(动词，直接宾语，名词)对和回应长度的分布比较GPT-3和GPT-4对同一组指令的生成差异，如图8-6和图8-7所示。这种分析不仅有助于评估数据，也有助于评估模型。



(c) Frequencies of top 25 verb-noun pairs



GPT-4似乎有更广泛、更多样化的动词-名词配对范围，并倾向于生成更长的回应。

按数据源、时间、注释者等绘制这些分布图。你是否注意到任何倾向于获得更长/更短回应或更高/更低分数的问题模式？有离群值吗？这些离群值的原因可能是什么？如何处理它们？

如果分数应遵循正态分布，所有注释者的分数是否遵循正态分布？你可能会注意到，一些注释者倾向于给出更短的回应或偏向更高分数，由你决定如何处理他们的注释。

如果每个示例有超过一个注释，计算注释者间不一致性。检查具有冲突注释的示例并解决冲突。

有许多数据探索工具可以使用，但它们不能替代手动数据检查。在我参与的每个项目中，盯着数据仅15分钟通常会给我一些见解，可能节省数小时的麻烦。OpenAI联合创始人Greg Brockman发推文说："手动检查数据可能在机器学习中任何活动中具有最高的价值对声望比率。"

查看你的数据，看看示例是否有意义。如果是注释数据，挑选几个查询自己尝试注释，看看你的注释是否与给定注释匹配。这将让你了解注释的可信度。事实检查回应。示例有多独特？有任何具有相同查询但不同回应的示例吗？有任何具有相同回应但不同查询的示例吗？

去重数据

重复数据可能扭曲数据分布并向模型引入偏见。想象表8-3所示的数据集。重复条目可能导致模型错误地得出所有红色物品都应该昂贵的结论。重复可能导致测试集污染。将重复数据分割到训练和测试集时，一个示例可能在训练集中，其副本在测试集中。

表8-3. 具有灰色单元格中重复示例的玩具数据集。

Table 8-3. A toy dataset with duplicate examples in grey cells.

	Input (Product description)	Output (Price)
1	{item: pencil, color: red}	\$20
2	{item: compass, color: green}	\$2
3	{item: pencil, color: red}	\$20
4	{item: pencil, color: red}	\$20
5	{item: pencil, color: green}	\$1

多项研究表明训练数据重复对模型性能的负面影响；参见Lee等(2021)和Tirumala等(2023)。Anthropic研究表明，重复0.1%的数据100次可能导致8亿参数模型的性能降级至4亿参数模型的水平，尽管其他90%的训练token保持唯一(Hernandez等，2022)。即使重复不损害模型性能，也会浪费时间和计算资源。

根据数据，有许多形式的重复，其中一些更难检测。例如，以下是文档数据集中的几种重复类型：

- 整个文档重复：同一文档多次出现。
- 文档内重复：例如，同一段落在一个文档中出现两次。
- 跨文档重复：例如，同一流行引用出现在多个文档中。

什么被视为重复也取决于你的定义。例如，你想处理文档级、段落级、句子级还是token级重复？两个文本必须完全匹配才被视为重复，还是80%重叠就足够？两个列表如果有相同项目但顺序不同是否被视为重复？

去重任务可以利用用于相似性测量的相同技术(在第3章讨论)。数据去重也用于身份解析,确定两个身份(例如,两个社交媒体档案)是否相同。以下是一些具体去重数据的方法:

成对比较

使用精确匹配、n-gram匹配、模糊匹配或语义相似性分数计算每个示例与数据集中每个其他示例的相似性分数,如第3章所讨论。然而,这种方法对大型数据集可能很昂贵。

哈希

将示例哈希到不同桶中,只检查落入同一桶中的示例。与哈希相关的去重方法包括MinHash和Bloom过滤器。

降维

使用降维技术首先减少数据维度,然后进行成对比较。如第6章所讨论,许多用于向量搜索的技术可用于此。

快速搜索将返回许多帮助去重的库。其中一些是dupeGuru、Dedupe、datasketch、TextDistance、TheFuzz和deduplicate-text-datasets。

清理和过滤数据

数据需要清理以使模型高性能和安全。

首先,你可能想删除多余格式化token。由于许多公共数据集是从互联网抓取的,多余HTML标签相当常见。除非你想训练模型处理HTML标签,否则删除它们。Databricks发现删除多余Markdown和HTML token将其模型准确率提高20%,同时将输入token长度减少60%。

你需要清理数据中任何不符合你政策的内容,如PII、敏感数据、版权数据或被视为有害的数据。第4章讨论的技术可以提供帮助。删除所有不允许使用的字段,如邮编、名称和性别。

你也可能想删除低质量数据,使用"数据验证"中讨论的技术检测低质量数据。

手动检查数据在这一步尤为重要。盯着数据可能帮助你注意可用作启发式方法检测低质量数据的模式。检测低质量数据的启发式方法可能不明显。例如,Kern等(2024)发现在注释会话后半部分所做的注释质量较低,可能由于注释者无聊或疲劳。

如果数据多于你需要或能负担使用的(例如,由于计算预算),你可以进一步过滤数据。例如,你可以使用主动学习技术选择对模型学习最有帮助的示例。你也可以使用重要性采样找到对你任务最重要的示例。它们的效率取决于你是否有效的方法来评估每个训练示例的重要性。Meta研究人员在他们关于数据剪枝的论文中(Sorscher等, 2022)得出结论,发现好的数据剪枝指标可以显著降低现代深度学习的资源成本。

格式化数据

一旦你去重和清理了数据，你需要将其转换为你微调的模型所期望的正确格式。如第5章所讨论，每个模型使用特定的标记器并期望特定聊天模板格式的数据。将数据放入错误的聊天模板可能导致模型中奇怪的错误。

如果你在做监督微调，你的数据很可能采用(指令，回应)格式。指令可以进一步分解为(系统提示，用户提示)。如果你从提示工程毕业到微调，用于微调的指令可能与用于提示工程的指令不同。在微调期间，指令通常不需要任务描述或示例。如果你有足够的训练示例，模型可以直接从示例中学习任务的预期行为。

例如，假设你一直使用这个三示例指令与基础模型进行食品分类任务：

将以下项目标记为可食用或不可食用。

Label the following item as either edible or inedible.

Item: burger
Label: edible

Item: car
Label: inedible

Item: mushroom
Label: edible

Item: {INPUT}
Label:

对于微调，包含在3示例提示中的所有示例都可以转换为训练示例。用于微调的训练数据将如表8-4所示。

表8-4. 用于食品分类任务的示例训练数据。

示例ID	输入	输出
1	汉堡 -->	可食用
2	汽车 -->	不可食用

3 蘑菇 --> 可食用

...

一旦模型微调完成，你可以使用如下简单提示：

{输入} -->

这比用于基础模型的提示短得多。因此，如果你担心指令的输入token数量，微调可以是帮助管理成本的一种方式。

不同的微调数据格式可能影响你微调后模型的性能。确定最适合你的格式的实验会很有帮助。

当你使用微调后的模型时，确保你使用的提示与微调数据的格式匹配。例如，如果训练数据使用"汉堡 -->"格式的提示，以下任何提示都可能导致问题：

- "汉堡": 缺少结束箭头
- "项目: 汉堡 -->": 额外前缀
- "汉堡 --> ": 附加额外空格

总结

尽管创建训练数据的实际过程非常复杂，但创建数据集的原则却出奇地简单。要构建训练模型的数据集，首先思考你希望模型学习的行为，然后设计展示这些行为的数据集。由于数据的重要性，团队正在引入专门的数据角色，负责获取适当数据集同时确保隐私和合规。

你需要什么数据不仅取决于用例，还取决于训练阶段。预训练需要的数据与指令微调和偏好微调不同。然而，跨训练阶段的数据集设计共享相同的三个核心标准：质量、覆盖和数量。

虽然模型训练所用数据量常常成为头条，但拥有具有足够覆盖的高质量数据同样重要。少量高质量数据可能优于大量嘈杂数据。同样，许多团队发现增加数据集多样性是提高模型性能的关键。

由于获取高质量数据的挑战，许多团队转向合成数据。虽然以编程方式生成数据长期以来一直是目标，但直到AI能够创建逼真、复杂的数据，合成数据才成为更多用例的实用解决方案。本章讨论了数据合成的不同技术，深入探讨了为微调合成指令数据。

就像真实数据一样，合成数据必须在用于训练模型前进行评估以确保其质量。评估AI生成数据与评估其他AI输出一样棘手，人们更可能使用他们能可靠评估的生成数据。

数据具有挑战性是因为数据集创建中的许多步骤不容易自动化。注释数据很难，但创建注释指南更难。自动化数据生成很难，但自动化验证更难。虽然数据合成有助于生成更多数据，但你不能轻易自动化思考你想要什么数据。你不能轻易自动化注释指南。你不能自动化关注细节。

然而，具有挑战性的问题导致创造性解决方案。在为本章做研究时，让我印象深刻的一点是数据集设计中涉及多少创造力。人们构建和评估数据的方式很多。我希望本章讨论的数据合成和验证技术范围能为你设计数据集提供灵感。

假设你已经策划了一个很棒的数据集，允许你训练一个了不起的模型。如何提供这个模型的服务？下一章将讨论如何优化推理的延迟和成本。